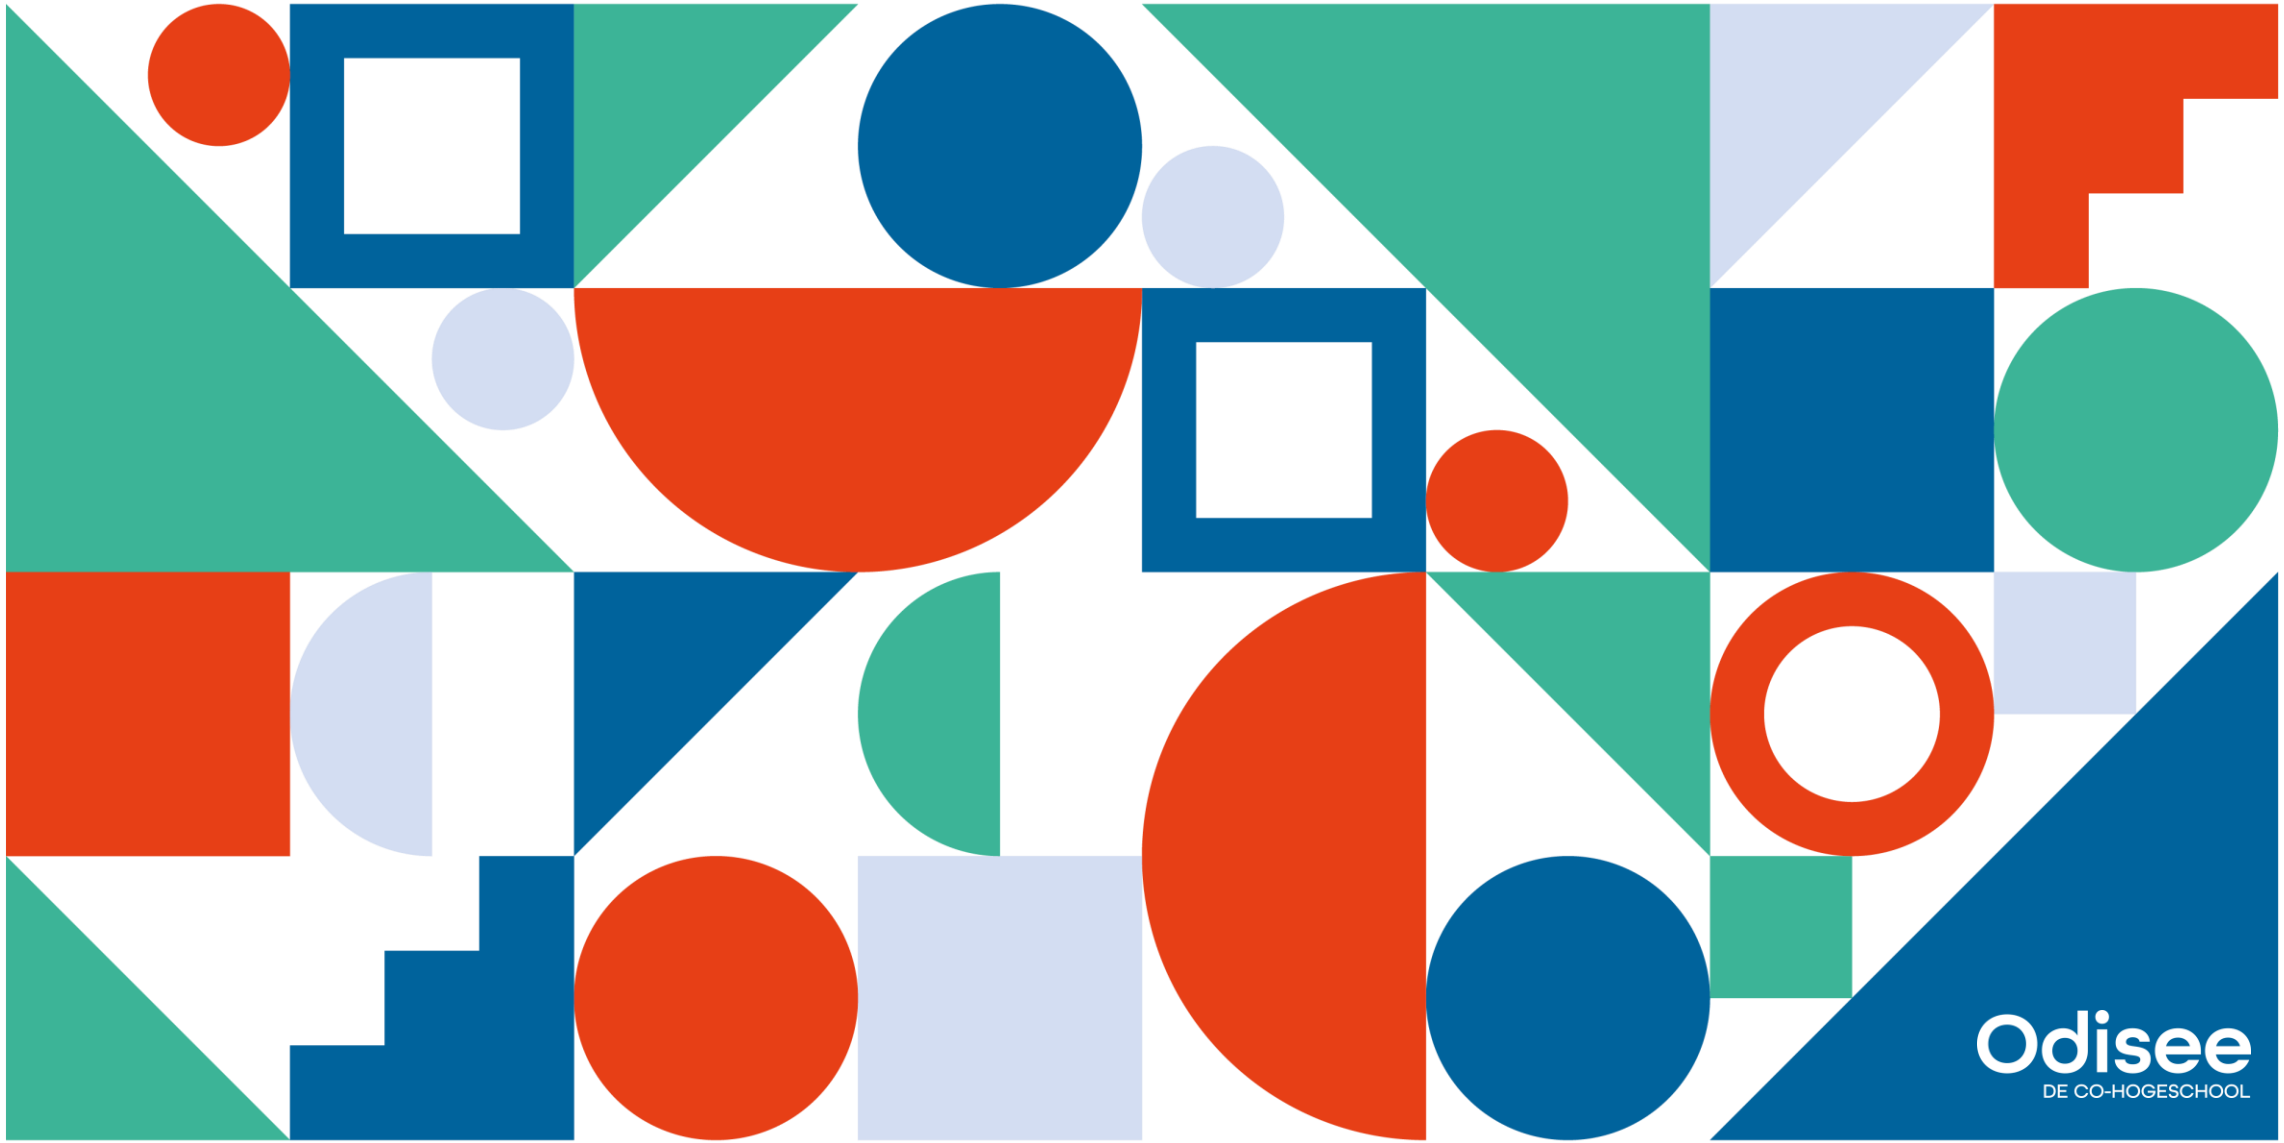
Odisee
DE CO-HOGESCHOOL

Big Data – HDFS operations

Jens Baetens

Schrijven van data

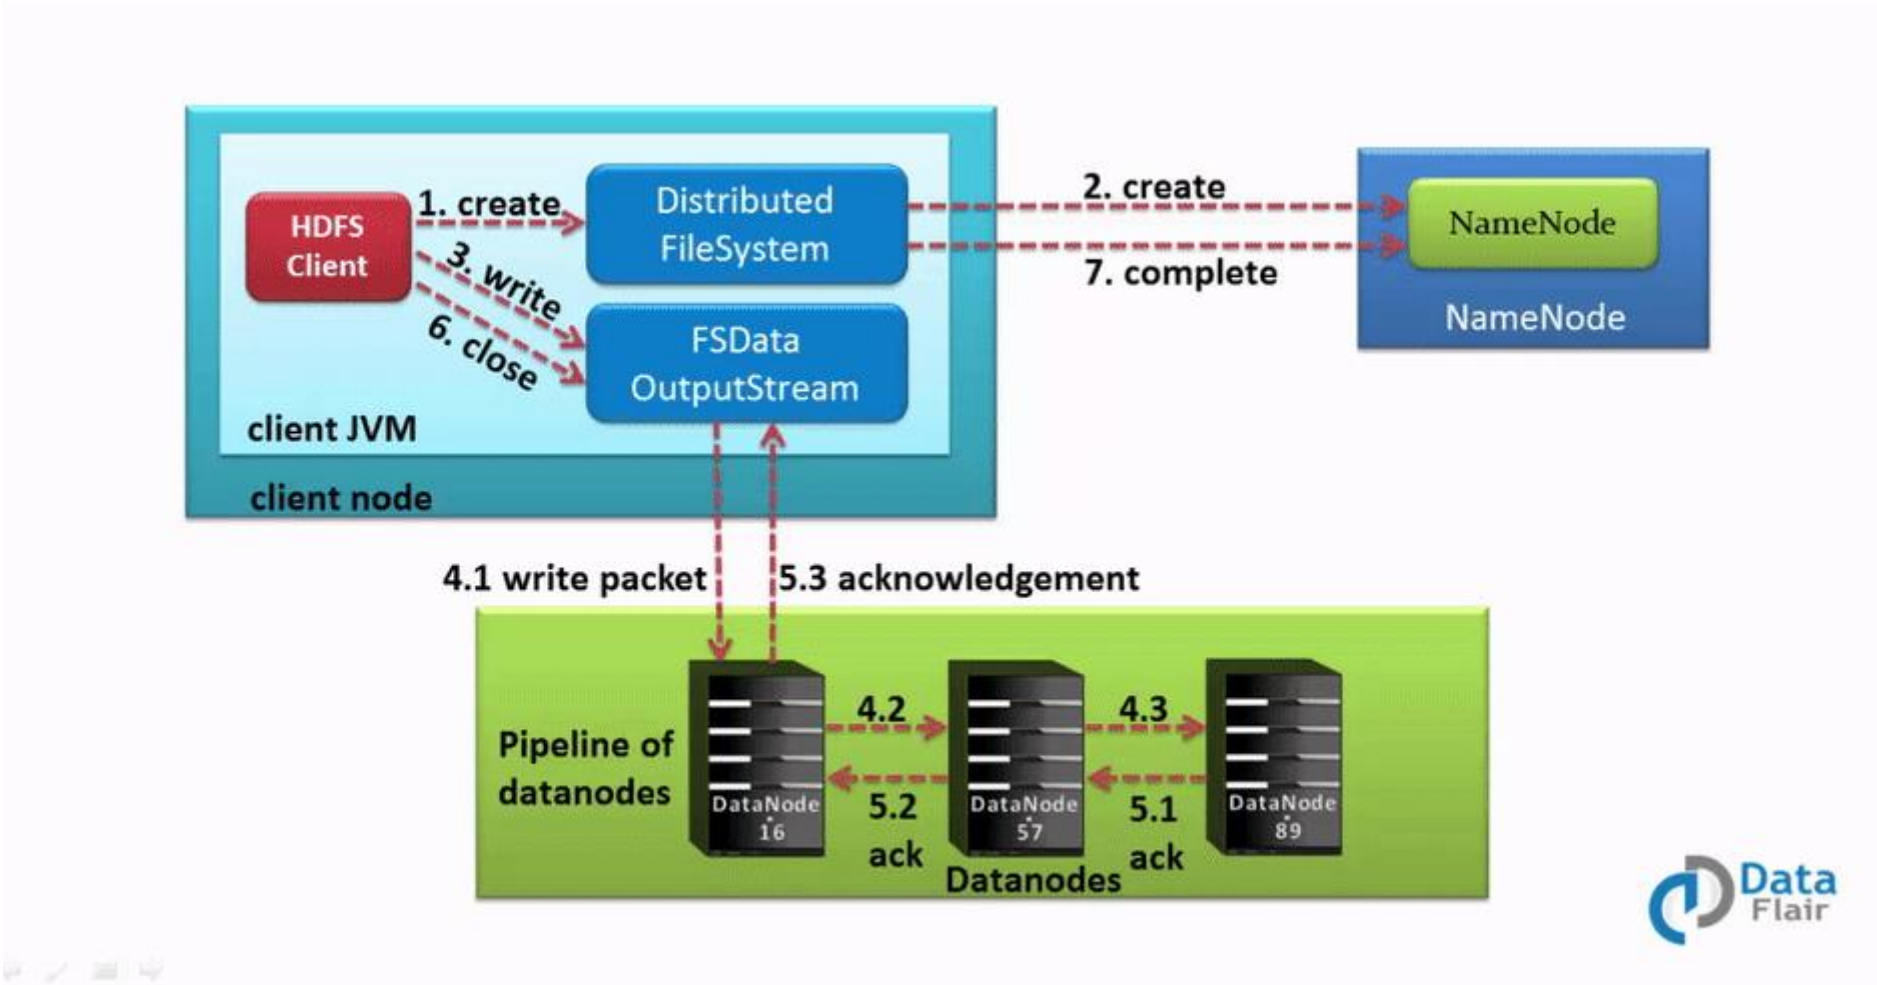

Wat met data consistentie?

- Data wordt achter elkaar geschreven van de ene datanode naar de andere
  - Lezen van data kan een willekeurige datanode kiezen waar de node op staat
  - Kan je dan nog de oude data lezen?
    - Ja
- Eventually consistent
  - Veel voorkomend concept
  - Ooit komt het in orde

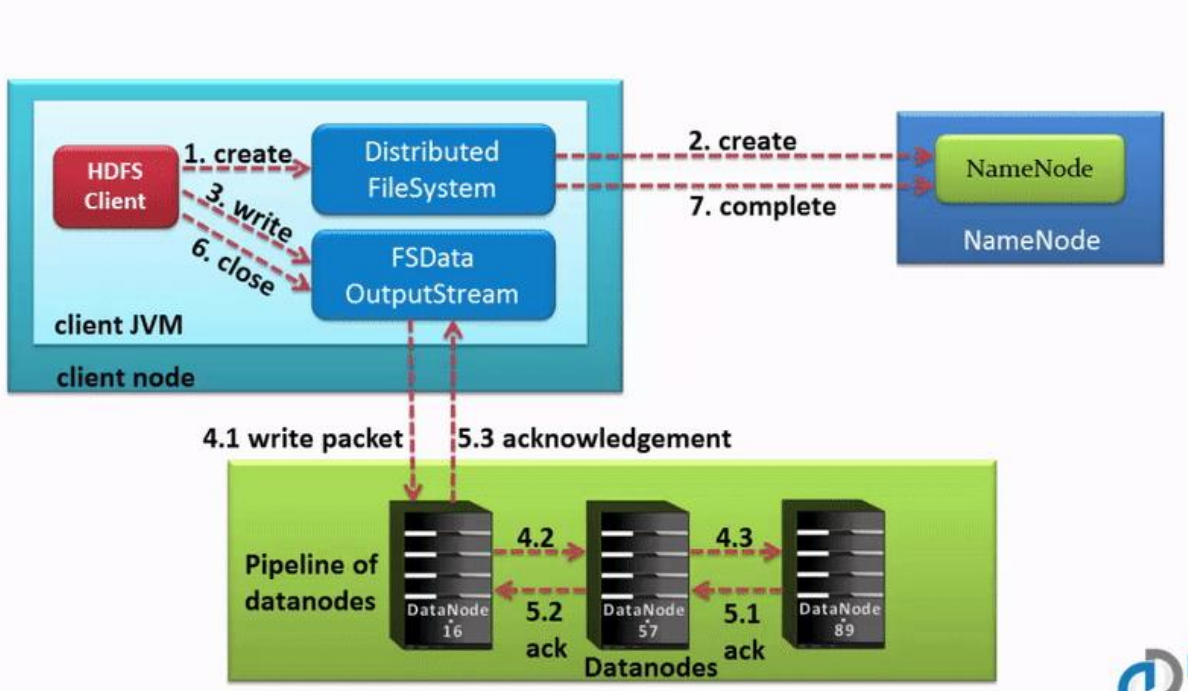

Hoe bewerken van een hdfs?

- Ofwel via commandline, communicatie met hdfs geconfigureerd in xml-files
  - https://www.informit.com/articles/article.aspx?p=2755708&seqNum=4
  - hadoop/etc/hadoop/core-site.xml
  - hadoop/etc/Hadoop/hdfs-site.xml
- Maak gebruik van libraries om met een HDFS te communiceren
  - Pydoop — Geavanceerdere taken
  - Snakebite — Eenvoudige taken
  - Hdfs — Eenvoudige taken
  - Pyspark — Data gebruiken

```
from snakebite.client import Client

client = Client('localhost', 9000)
for x in client.ls(['/']):
    print x
```

commando's uitvoeren

HdfsCLI – python bindings

- API: https://hdfscli.readthedocs.io/en/latest/
- Bevat functies voor
  - te lezen
  - te schrijven
  - te verkennen
  - te manipuleren

Aanmaken van bestanden en folders

CLI

- Exists: hdfs dfs -test -d hdfs_path
- Mkdir: hdfs dfs -mkdir -p /bigdata/HDFS
- hadoop fs -put /path/in/linux /hdfs/path
- hadoop fs -get /hdfs/path /path/in/linux

Python

- status = client.status(path, strict=False)
- client.makedirs(path)
- client.upload(hdfs_path, local_path)
- client.download(hdfs_path, local_path)

Bekijken van het filesysteem

- hdfs dfs -ls command
- hdfs dfs –usage
- hdfs dfs -cat <hdfs_filename> | head -n 5

- client.list(path, status=True)
- client.status(path, strict=False)

```
with client.read(path) as reader:
    for i, line in enumerate(reader):
        if i >= num_lines:
            break
        print(line.decode('utf-8').strip())
```

Aanpassen van het filesysteem

- hadoop fs -mv oldname newname
- hdfs dfs -rm path (-r voor folders)
- hdfs dfs –setrep –w 3 /tmp/logs/file.txt

- client.rename(old_path, new_path)
- client.delete(path, recursive=recursive)
- client.set_replication(path, replication)

Welke processen zijn er allemaal nodig voor een HDFS?

- Namenode
  - Beheren van de file system namespace and reguleren van toegang tot bestanden
  - http://localhost:9870
- SecondaryNamenode
  - Backup van de primaire namenode
  - http://localhost:9868

Welke processen zijn er allemaal nodig voor een HDFS?

- Datanode
  - normaal 1 per node in de cluster
  - manage storage attached to the nodes that they run on
  - http://localhost:9864

Welke processen zijn er allemaal nodig voor een HDFS?

- Nodemanager
  - Verantwoordelijk om containers te starten en te beheren op een node. Containers voeren taken uit gegeven door de AppMaster.
  - http://localhost:8042
- Resourcemanager
  - Verantwoordelijk voor het beheren van de beschikbare resources en plannen van applicaties
  - http://localhost:8088

- Lijst van alle gebruikte poorten: https://kontext.tech/article/265/default-ports-used-by-hadoop-services-hdfs-mapreduce-yarn

https://youtu.be/4Gfl0WuONMY