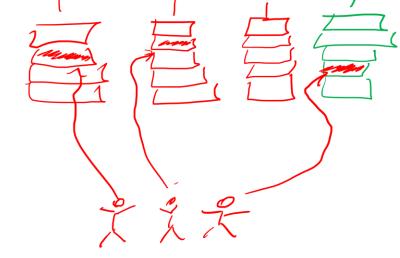


Big Data - Distributed storage



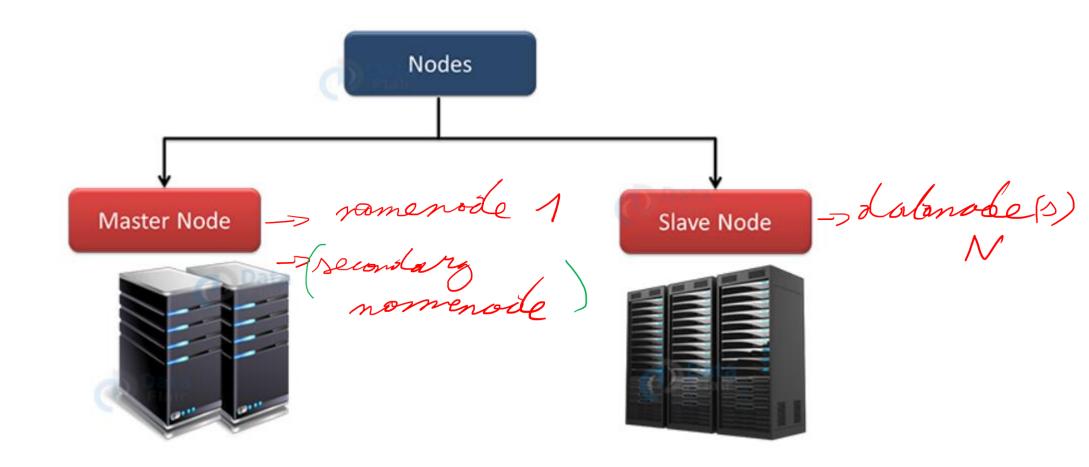
Wat is HDFS?

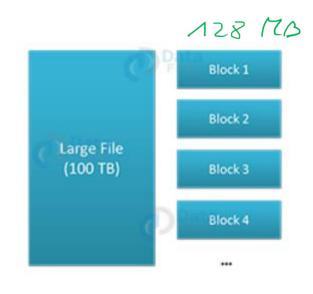
- Distributed File Storage
- Cluster van commodity hardware
- Fault Tolerance door replicatie van files
 - Verschillende racks, datacenters, continenten
- Scalable
 - Extra nodes kunnen eenvoudig toegevoegd worden
- Parallelle data access

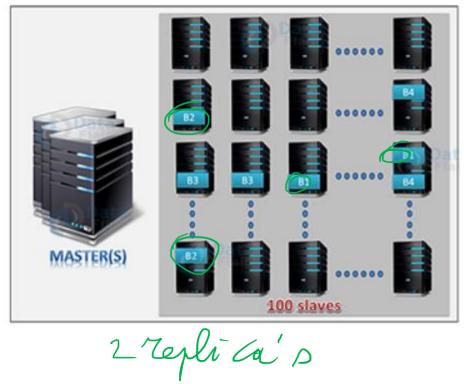


Coles gan problem consistent - non-blakens

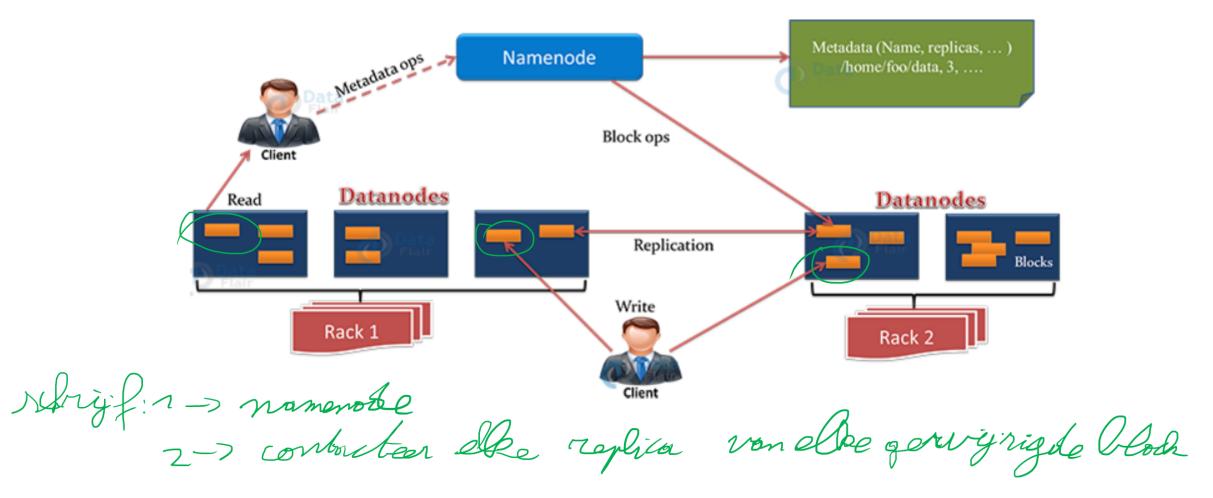
strict consistent - blocking 3







m læss næmenode Word? 2. Contacteur alle blocks amte læren



Features – Distributed storage

- Onderverdeel files in kleinere delen (Blocks)
- Verdeel de blokken over de nodes
- Repliceer de blokken het gewenste aantal keren (minstens 1 op een andere rack)

Features - Blocks

- Default block size is 128 MB
 - File van 150 MB wordt dus gesplitst in 128 MB en 22 MB
- Beheer van de blokken volledig door de namenode
- Voordeel van grotere block-sizes is dat
 - de file sneller ingelezen wordt
 - Map reduce voert functie uit per block dus niet te veel blocks gewenst.

Features - Replication

- Het aantal keer dat eenzelfde blok voorkomt over alle datanodes
- Dit verhoogt de beschikbaarheid van een blok omdat indien een node crashed, de data beschikbaar is op een andere node.

■ Er wordt gepoogd minstens 1 replica op een andere node te plaatsen

■ Default waarde is 3

Features – High availability, data reliability en fault tolerance

■ Datanode fails

- Datanode stuurt heartbeat naar de namenode -> detecteren van crashed datanode
- Datanode crashed tijdens opvragen gegevens -> vraag nieuwe locatie aan namenode

■ Namenode fails

- In de master-slave architectuur is de master een single point of failure
- Vanaf Hadoop 2.0 is er een secondary namenode
- Consistency bij gebruik van meerdere namenodes vereist extra aandacht
 - Identieke gegevens in primary en secondary namenode
 - Wat bij terug online komen van primary namenode

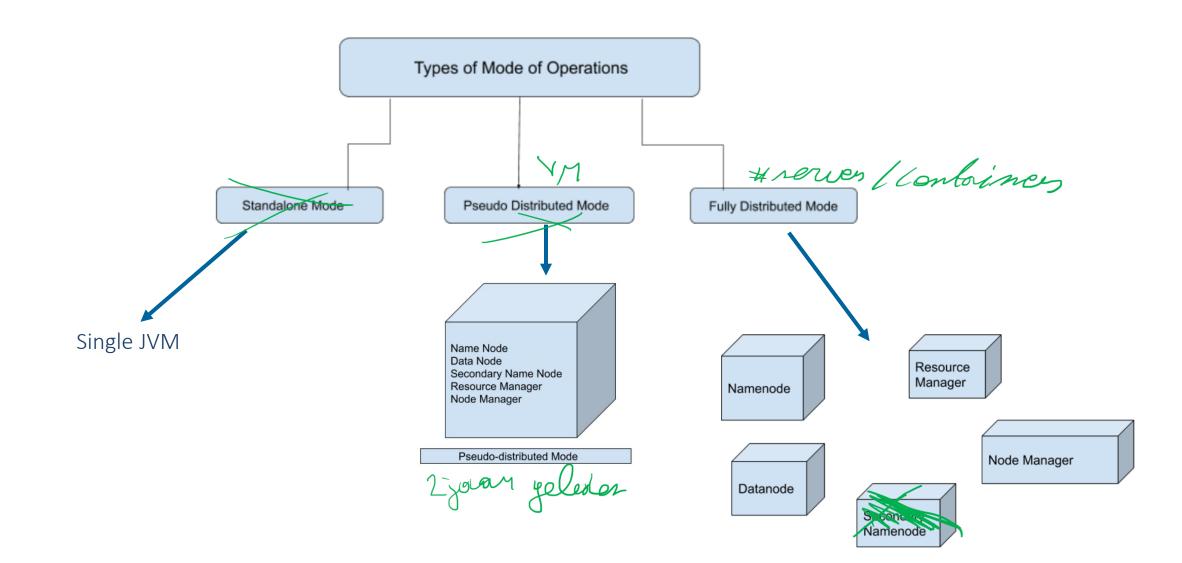
Features - Scalability

- Vertical scaling
 - Meer HDD's in een node
 - Heeft downtime nodig (om HDD te installeren)
- Horizontal scaling
 - Extra noden toevoegen aan cluster

Features – High throughput

- Throughput = Hoeveel werk dat gedaan wordt per seconde/minuut/...
- Data wordt parallel gelezen, het werk wordt verdeeld door de verschillende systemen

Hadoop working modes



Leg de volgende termen uit

- Horizontal scaling Degin les

■ Replication

Block

Wat moet je kunnen uitleggen?

- Via welk systeem wordt er fault-tolerance ingebouwd in een HDFS?
- Via welk systeem wordt de benodigde rekenkracht verspreid in een HDFS?
- Wat is het verschil tussen horizontal en vertical scaling?
- Wat zijn de voordelen van horizontal scaling?