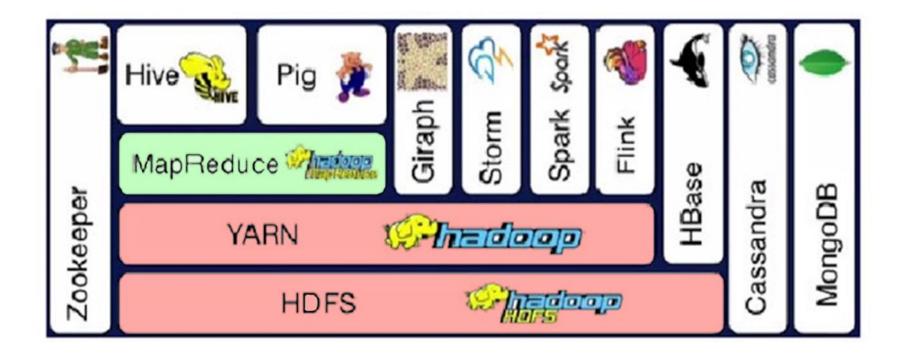


# Big data – Map reduce



**Jens Baetens** 

## **Hadoop Ecosystem**



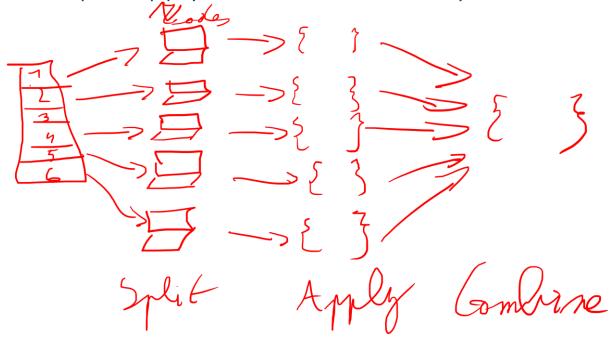
# Wat is map reduce?

### **Geschiedenis**

- 2004: Jeffery Dean and Sanjay Ghemawat (Google) introduceerden het begrip in de paper: MAPREDUCE: SIMPLIFIED DATA PROCESSING ON LARGE CLUSTERS
- Essentieel onderdeel van Google Search en heeft Google groot gemaakt
  - Gebruikt tot 2014
- Originele data-processing layer van het Hadoop Ecosysteem
- Heel schaalbaar door big data te verdelen in kleinere delen Divio e & Conquer
- Basis-idee van heel veel distributed toepassingen

# ■ Programmeermodel

- Map Reduce van functioneel programmeren
- Split-Apply-Combine Data analysis





### Voordelen

- Eenvoudig model
  - Geen zorgen om parallellisatie, data passing, race conditions, ...
- Scalable
- Structured en unstructured data
- Fault Tolerance
  - Master/Slave architectuur maakt het mogelijk om crashes te omzeilen (Automatic recovery)

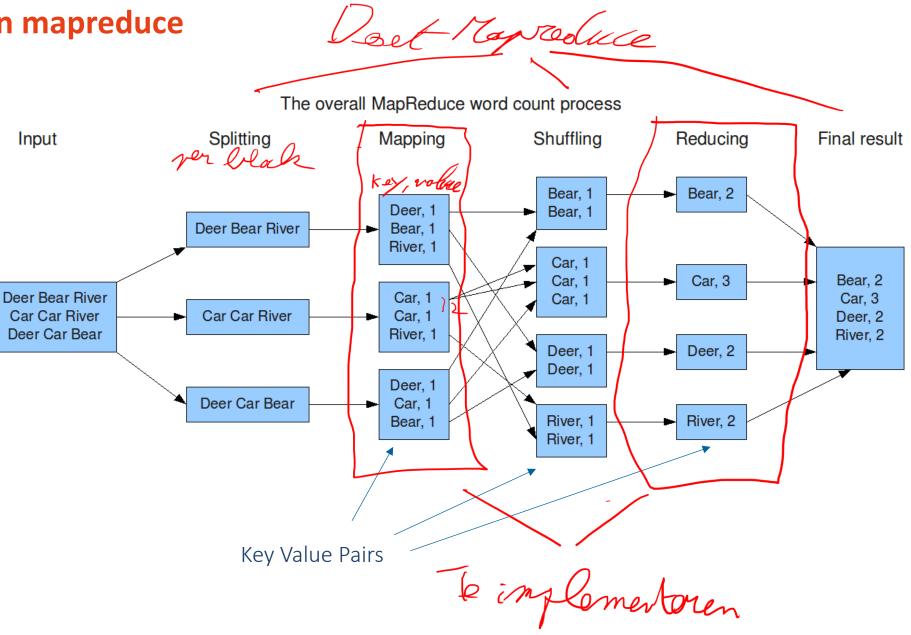
## Nadelen/kritieken

HDD -> HDD -> HDD -> HDD in Sport. RAM RAM Seer meller

- Performance
  - Niet het snelste door steeds alles van disk te lezen (HDFS)
  - Wel heel schaalbaar
- Low-level programmeermodel -> veal reff to implementarion
- Restricted framework
  - Acyclic dataflow program zonder state
  - Herhaaldelijk opvragen van dezelfde datasets is traag (nadelig voor ML)

# Onderdelen

## Flow van mapreduce



### **3 Operaties**

#### The overall MapReduce word count process Splitting Mapping Shuffling Reducing Final result Input Bear, 2 Bear, 1 Deer, 1 Bear, 1 Deer Bear River Bear, 1 River, 1 Car, 1 Car, 3 Car, 1 Bear, 2 Car, 1 Deer Bear River Car, 3 Car, 1 Car Car River Car Car River Deer, 2 Car, 1 Deer Car Bear River, 2 River, 1 Deer, 2 Deer, 1 Deer, 1 Deer, 1 Deer Car Bear Car, 1 River, 2 River, 1 Bear, 1 River, 1

### Map

- Elke node voert dit uit op zijn data
- Lijn per lijn wordt file uitgelezen
- Master node vermijdt replica's
- (key, value) worden uitgestuurd en opgeslagen in tijdelijke opslag

### ■ Shuffle

Groepeer alle (key, value) paren met dezelfde key op 1 node

#### ■ Reduce

Verwerk elke key in parallel

## 5 stappen

- Prepare the input (YARN)
- Run the Map() code (Zelf gecodeerd)
- Shuffle Map to Reduce (Doet MapReduce)
- Run the Reduce() code (Zelf gecodeerd)
- Produce final output (Doet MapReduce)

### **Performance**

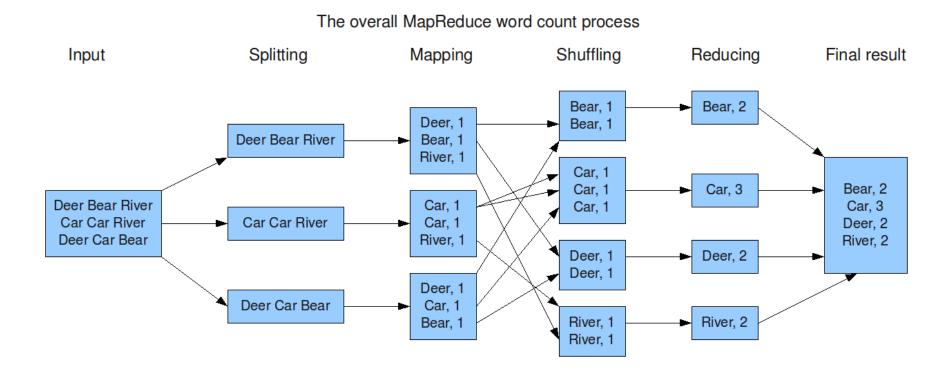
- Niet gegarandeerd snel maar wel in staat om heel veel data te verwerken
- Output of Map() wordt naar disk geschreven
- Enkel Map() en Reduce() worden parallel uitgevoerd
- Keys worden gesorteerd (kan lang duren)
- Communicatie tussen nodes zorgt ook voor delay

### **Fault Tolerance**

Lrecovery gebeut voor jou

- Voor taken die snel uitgevoerd worden
  - Herstarten van een enkele map() of reduce() is mogelijk
- Voor taken die langer duren kunnen tussentijdse resultaten gebruikt worden
  - Deze worden standaard opgeslagen

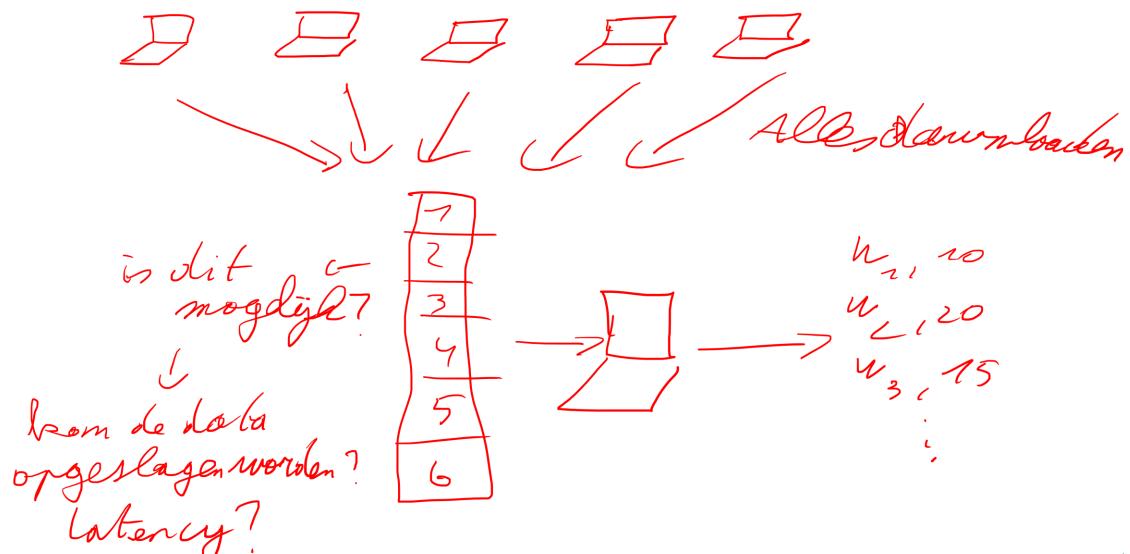
# **Typisch voorbeeld: Word Count**



# **Inputs - Outputs**

■ Alles geinterpreteerd als key-value pairs

# Word count voorbeeld: Hoe werkt het bij Data to Compute



# Word count voorbeeld: Hoe werkt het bij Compute to Data

# **Applicaties**

### **Voorbeeld - wordcount**

File information - input.txt

 $\times$ 

Download

Head the file (first 32K)

Tail the file (last 32K)

Block information -- Block 0 v

Block ID: 1073741912

Block Pool ID: BP-1244815758-127.0.1.1-1636028879278

Generation Stamp: 1088

Size: 111 Availability:

bigdata-VirtualBox

#### File contents

Hello World,

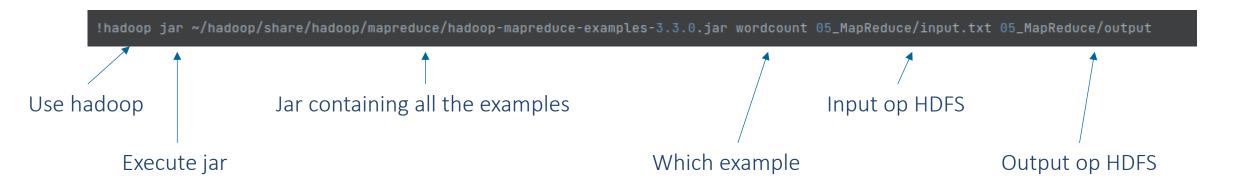
hello world, hello world,

Dit is een voorbeeld file om het Wordcount voorbeeld te testen!

Dit 1 Hello 1 Wordcount World, een 1 file 1 hello 2 het 1 is 1 om 1 te 1 testen. 1 voorbeeld world, 2

### Wordcount

■ Standaard geincludeerd bij installatie met Hadoop.



■ Andere applicaties die reeds bestaan:

!hadoop jar ~/hadoop/share/hadoop/mapreduce/hadoop-mapreduce-examples-3.3.0.jar

# WordCount zelf implementeren - JAVA

### Mapper

```
// Mapper de classes na extends Mapper<> zijn input-key, input-value, output-key, output-value
public static class TokenizerMapper extends Mapper<Object, String, String, Integer>{

    public void map(Object key, String value, Context context) throws IOException, InterruptedException {

        // value bevat de tekst in de huidige blok

        // de StringTokenizer maakt het mogelijk om over elk woord te lopen

        StringTokenizer itr = new StringTokenizer(value);

        // while-loop over alle woorden in de blocks op elke node

        while (itr.hasMoreTokens()) {

            // voeg een entry toe voor elk woord dat gezien wordt (deze worden in de reduce opgeteld)

            context.write(itr.nextToken(), 1);
        }
    }
}
```

# **WordCount zelf implementeren - JAVA**

### ■ Reducer

```
public static class IntSumReducer extends Reducer<String, Integer, String, Integer> {
   public void reduce(String key, Iterable<Integer> values, Context context) throws IOException, InterruptedException {
        for (int val : values) {
            sum += val;
        context.write(key, sum);
```

# WordCount zelf implementeren - JAVA

# Configuration

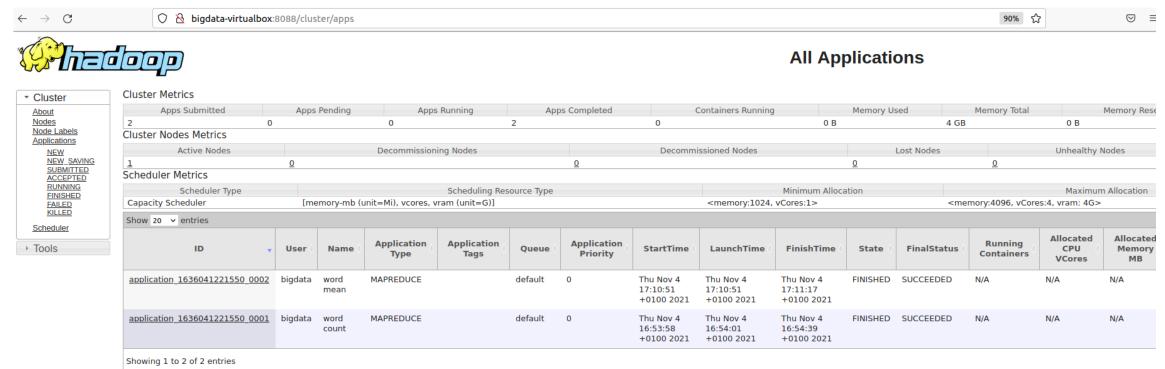
```
// configure the MapReduce program
public static void main(String[] args) throws Exception {
   Configuration conf = new Configuration();
   Job job = Job.getInstance(conf, "word count java");
   job.setJarByClass(WordCount.class);
   job.setMapperClass(TokenizerMapper.class);
   job.setCombinerClass(IntSumReducer.class);
   job.setReducerClass(IntSumReducer.class);
   job.setOutputKeyClass(Text.class);
   job.setOutputValueClass(IntWritable.class);
   FileInputFormat.addInputPath(job, new Path(args[θ]));
   FileOutputFormat.setOutputPath(job, new Path(args[1]));
   System.exit(job.waitForCompletion(true) ? 0 : 1);
```

- Voor het maken van deze applicaties heb je de volledige java programmeertaal tot je beschikking.
- Meer informatie over de specifieke Mapper/Reduce/ Combiner klassen vind je hier:

https://hadoop.apache.org/docs/stable/api/org/apache/hadoop/mapred/package-summary.html

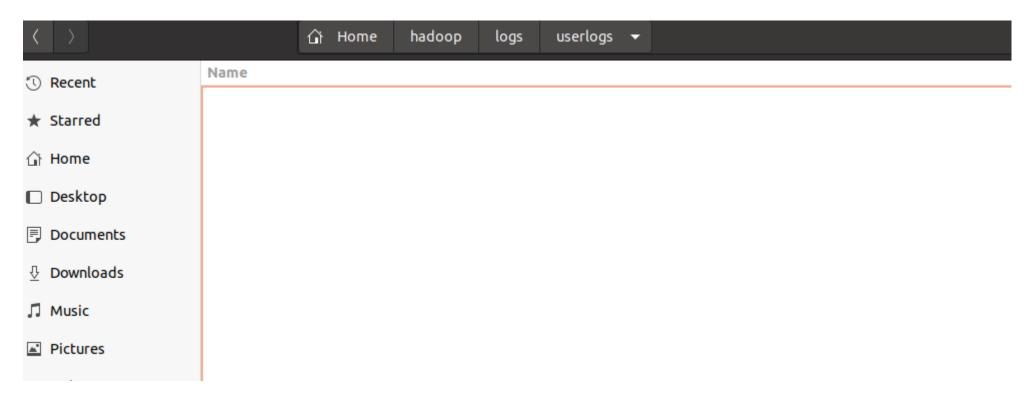
# **Track application state**

■ Yarn tracked de uitgevoerde applicaties en houdt hun logs bij.



# Logs

■ Of je kan ze ook in je Hadoop – folder vinden onder logs/userlogs



# Mapreduce coderen in Java

- Maximale flexibiliteit
- Snelste uitvoering
- Beste integratie met Hadoop

### API's voor andere programmeertalen

- Hadoop Streaming API
  - Door gebruik te maken van stdin en stdout om te communiceren
  - MrJob, dumbo, hadoopy
- Hadoop Pipes
  - C++ interface voor MapReduce, communicatie via sockets
  - pydoop
- Non-Hadoop
  - Disco, octopy

# **Mrjob (Hadoop Streaming)**

- Voordelen
  - Uitgebreidde documentatie
  - Code kan lokaal uitgevoerd worden
  - Veel management automatisch
  - Werkt met cloud toepassingen
    - Google Dataproc
    - Amazon Elastic
- Maar beschikt niet over de volledige Hadoop API

### **Mrjob (Hadoop Streaming)**

```
from mrjob.job import MRJob
class MRWordCount(MRJob):
   def mapper(self, _, line):
       for word in line.split():
           yield (word, 1)
   def reducer(self, word, counts):
       yield (word, sum(counts))
if __name__ == '__main__':
   MRWordCount.run()
```

!python wordcount\_mrjob.py -r hadoop hdfs:///user/bigdata/05\_MapReduce/input.txt > output.txt

# **Pydoop**

- Meer informatie / API / Examples: <a href="https://crs4.github.io/pydoop/index.html">https://crs4.github.io/pydoop/index.html</a>
- Beschikt in tegenstelling tot Mrjob wel over de volledige Hadoop Interface.
- Kan ook aanpassen hoe de bestanden ingelezen worden (bvb niet lijn per lijn)
- Pydoop script om python code uit te voeren

# **Pydoop script**

```
Jdef mapper(_, text, writer):
    for word in text.split():
        writer.emit(word, 1)
def reducer(word, icounts, writer):
    writer.emit(word, sum(icounts))
```

!pydoop script wordcount\_script.py 05\_MapReduce/input.txt 05\_MapReduce/output\_python\_script



https://youtu.be/bcjSe0xCHbE?list=PLQ4IP5lBsAQdCdLCkYUTyOQMR7Nyv3Wfk