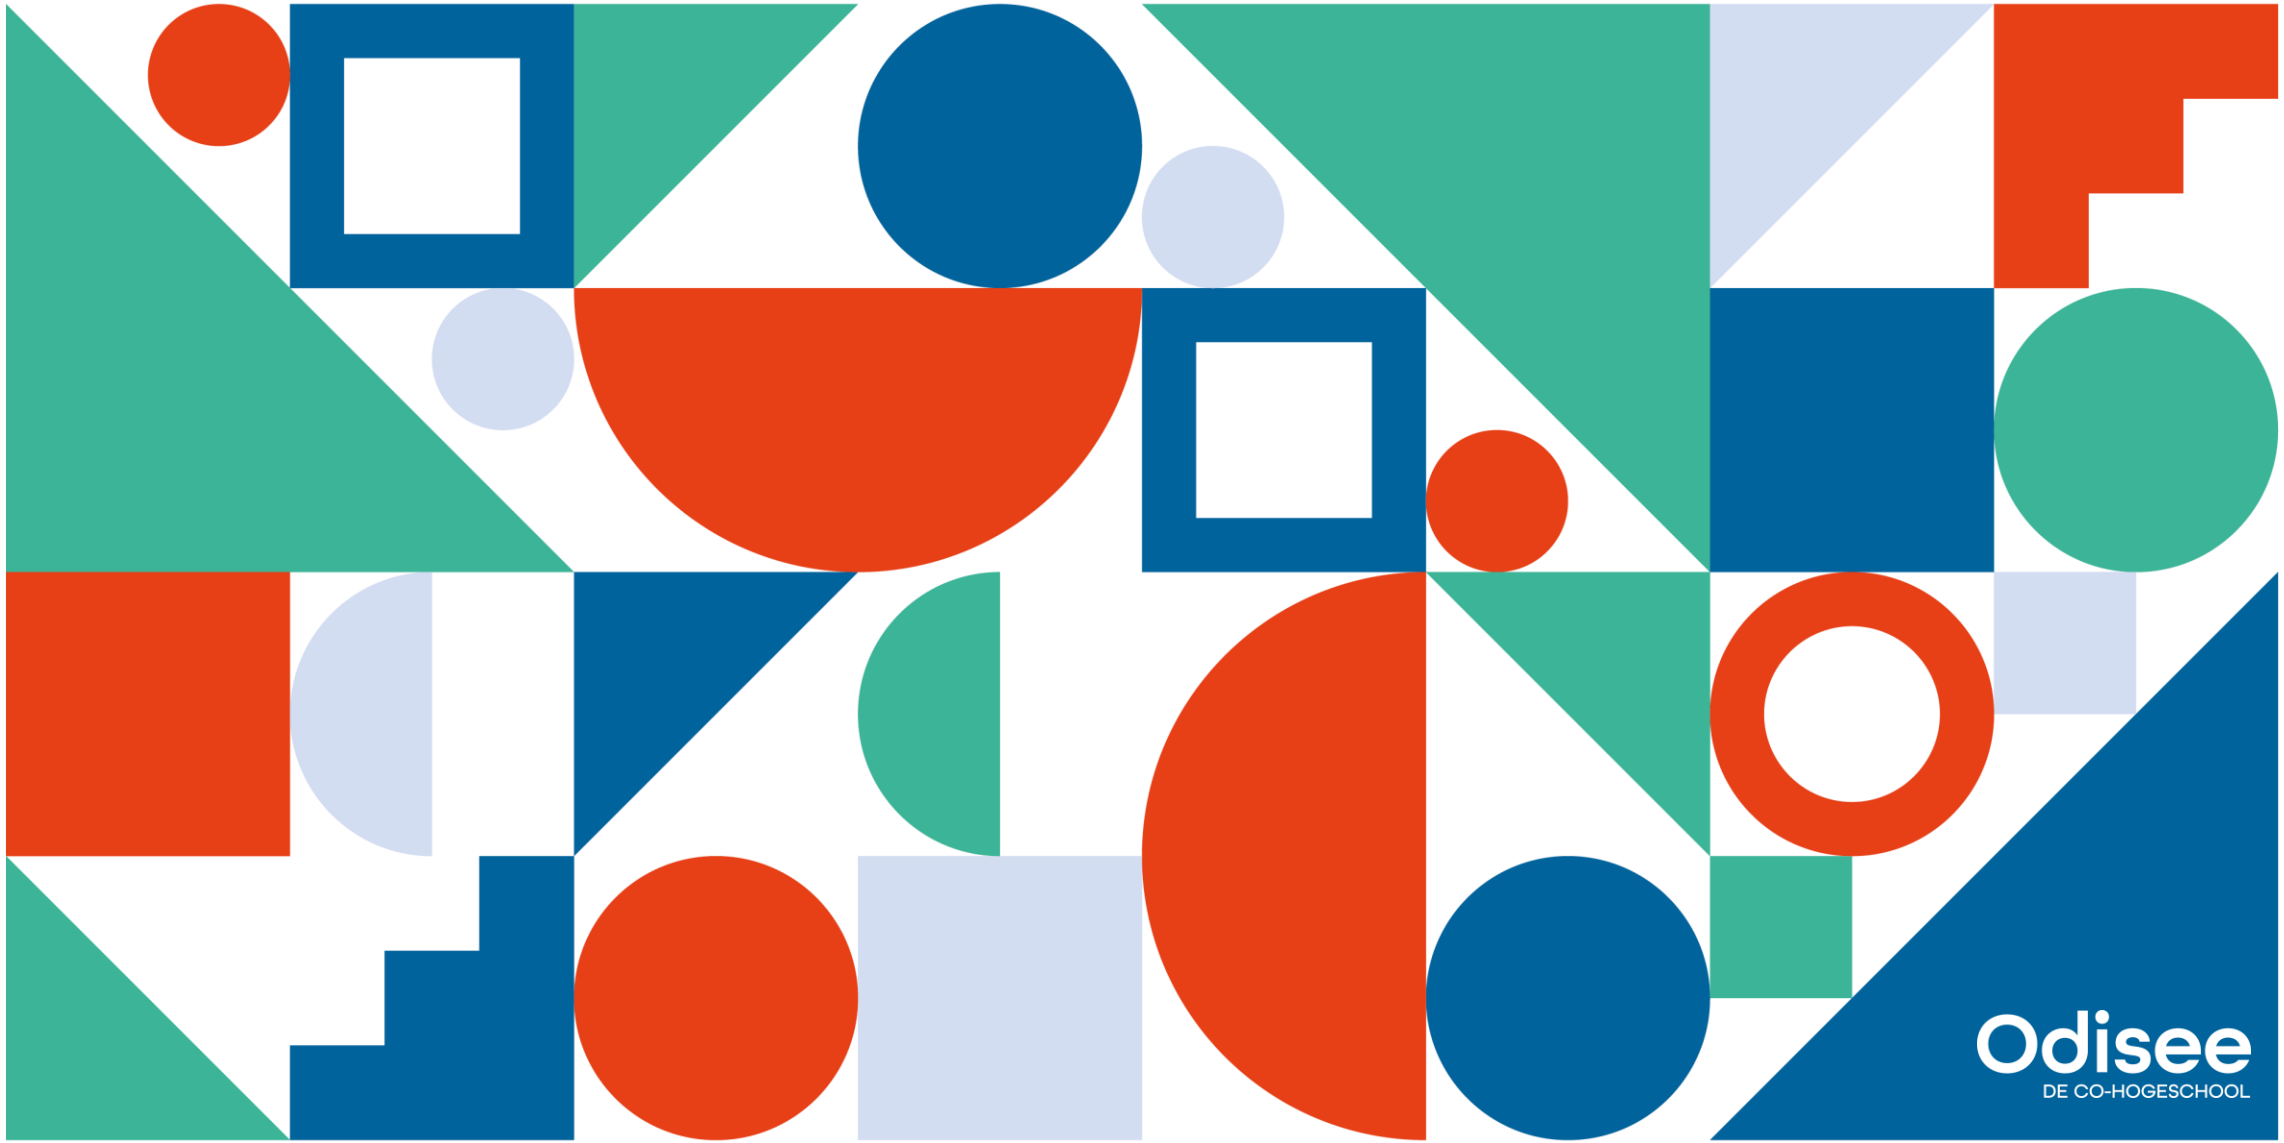
Odisee
DE CO-HOGESCHOOL

Big Data - Spark

Jens Baetens

Hadoop Ecosystem

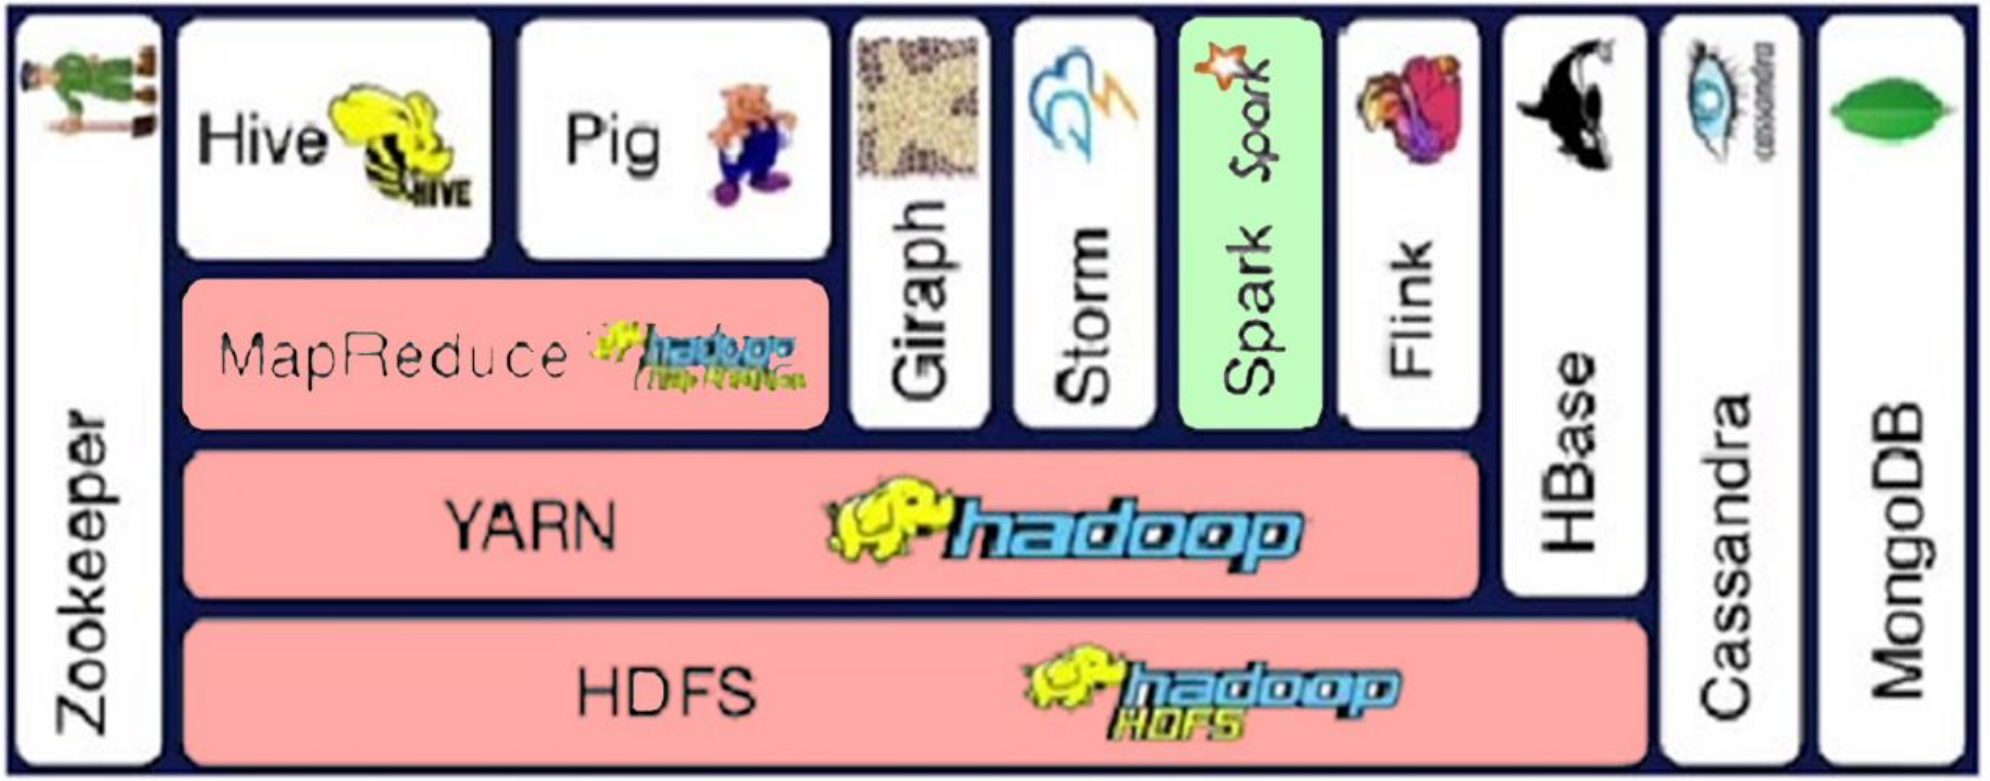

Wat is Spark?

Probleem met Hadoop

- Voordelen Hadoop
  - Eenvoudig programmeermodel
  - Schaalbaar
  - Goedkoop
  - Flexibel
  - Fout-tolerantie
- Maar: Niet snel!

Spark

- Geintroduceerd om de rekenlaag van Hadoop te versnellen
- Heeft zijn eigen cluster-beheer
  - Geen andere versie van Hadoop
  - Niet afhankelijk van Hadoop

- 2 delen
  - Storage -> Hiervoor kan Hadoop gebruikt worden
  - Processing

Features

- Speed: in memory-processing
- Ondersteuning voor verscheidene talen (bvb: Python, Java, Scala)
- Geavanceerde Analytics
  - MapReduce
  - SQL
  - Streaming
  - Machine Learning
  - Graph algoritmes → Dit gaan we niet in code zien

Modes van Spark

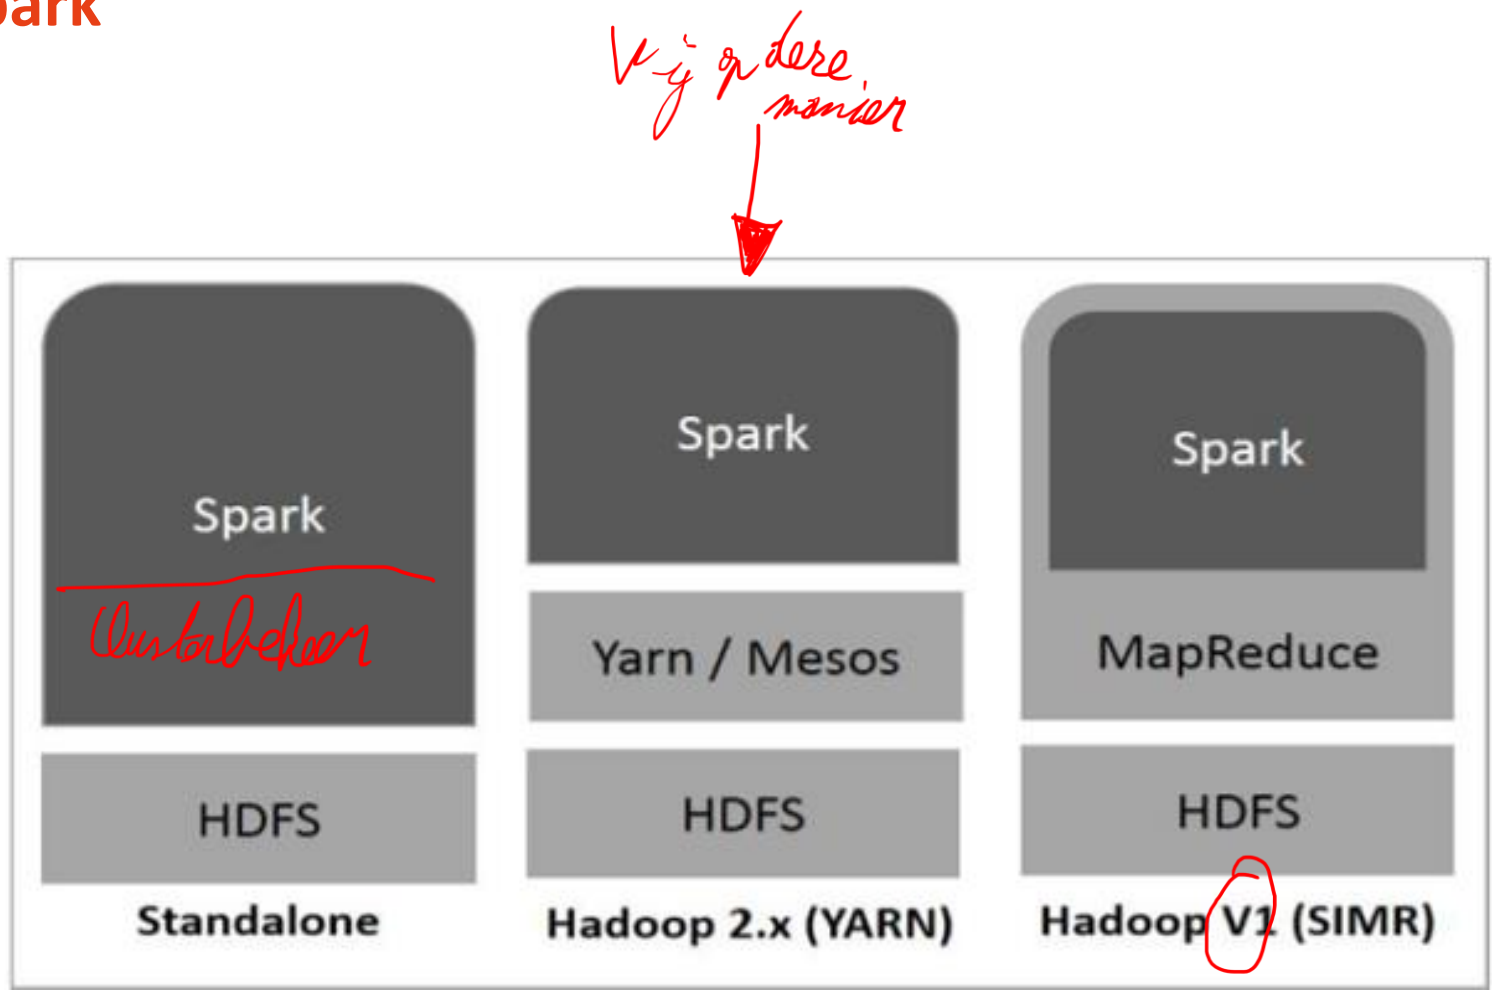

Componenten

- Spark Core
  - Execution engine
  - In-memory computing
  - External Datasets (HDFS)
- Spark SQL
  - (Semi) structured Data
  - Distributed Database
  - RDD – Resilient Distributed Datasets

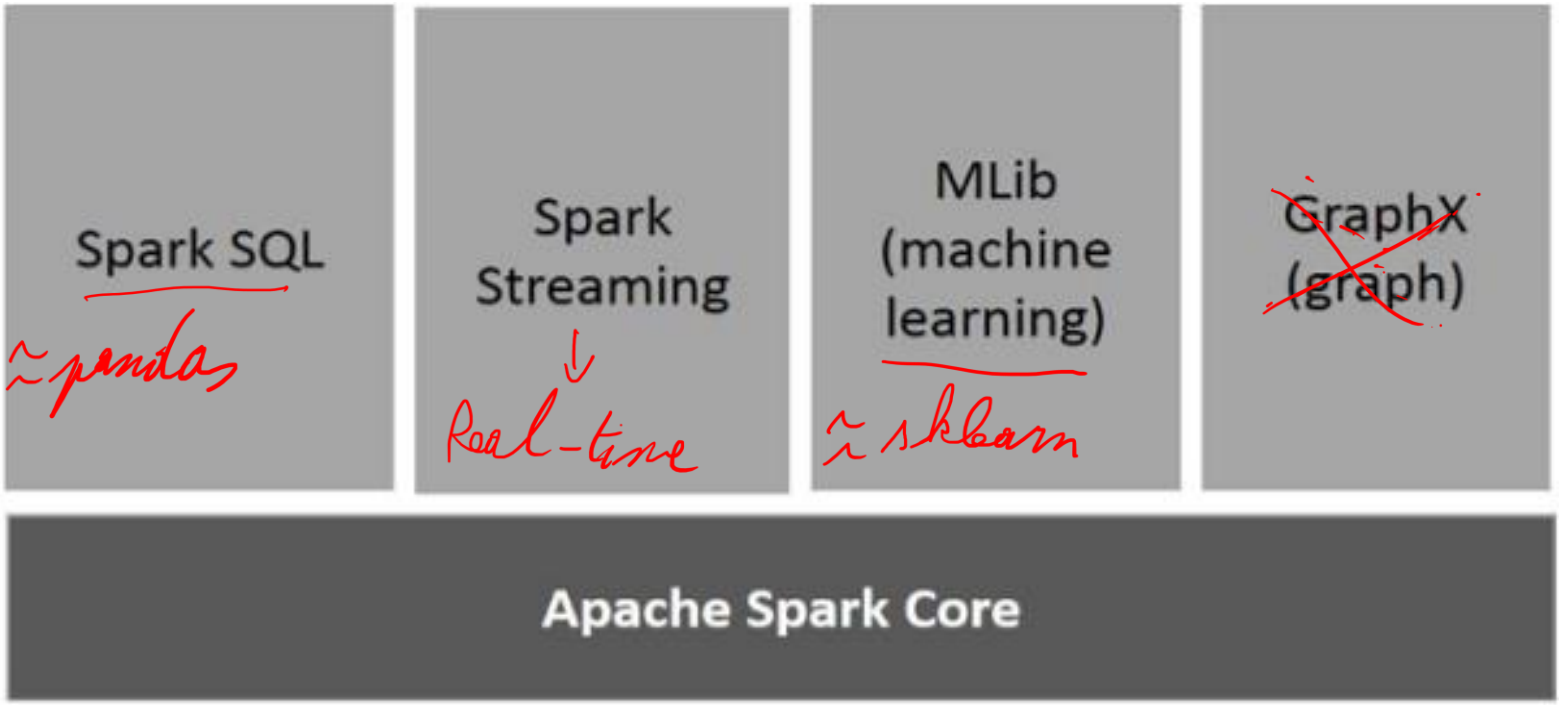

Componenten

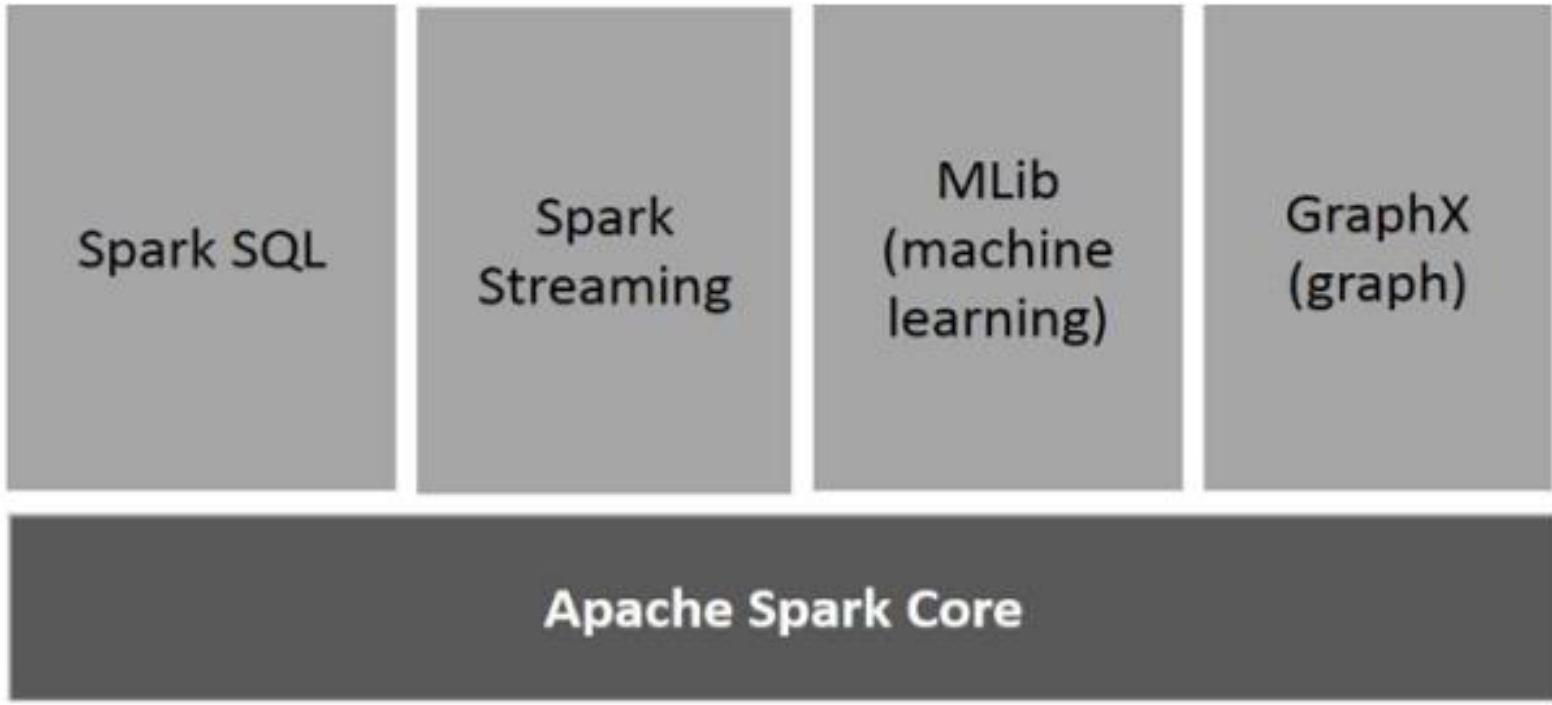

- Spark Streaming
  - Streaming analytics
  - Verwerk data in mini-batches
  - Voer RDD transformaties uit
- MLlib
  - Distributed machine learning framework
  - 9 x sneller dan Mahout (ML via MapReduce)

Componenten

- GraphX
  - Graph Processing Framework

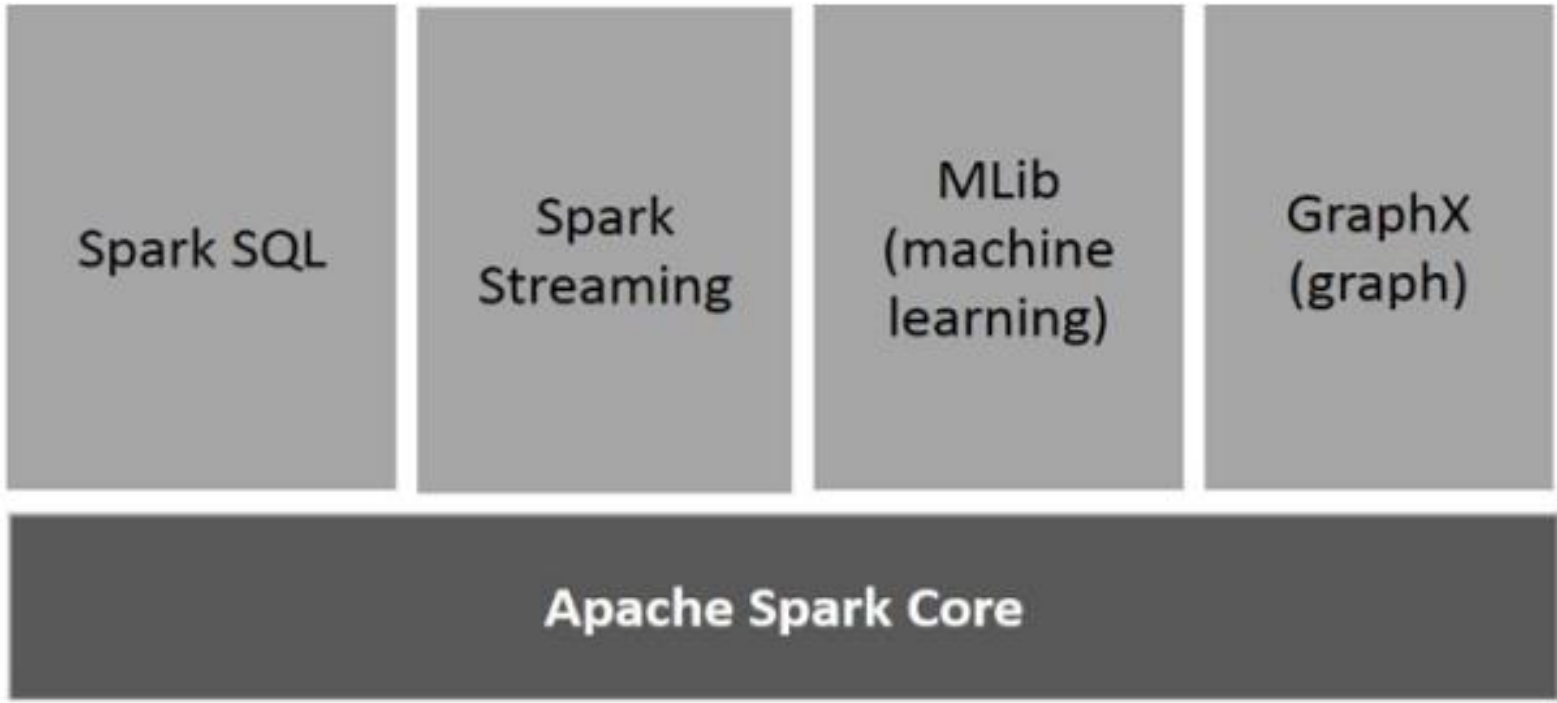

Spark

Storage	HDFS	Leverage Existing
MapReduce	✓	✓ → Enveloping Complex Transformations
Speed	Fast	10 - 100 X Faster
Resource Management	YARN	Standalone

Onderdelen van Spark

1. Spark SQL
2. Spark Streaming
3. MLLib
4. GraphX

https://youtu.be/ymtq8yjmD9I

Spark SQL

Resilient Distributed Datasets

- Distributed collectie van objecten
- Fout tolerante read-only gepartitioneerde collectie van gegevens
- Aangemaakt door
  - Parallelliseren van een bestaande collectie
  - Inladen van een dataset in een externe opslagsysteem (Shared file system, HDFS, HBase, SQL, …)

Probleem met map-reduce

- Delen van data is traag
  - Replication
  - Serialization
  - Disk IO
- 90% van de tijd in HDFS read-write

Iterative

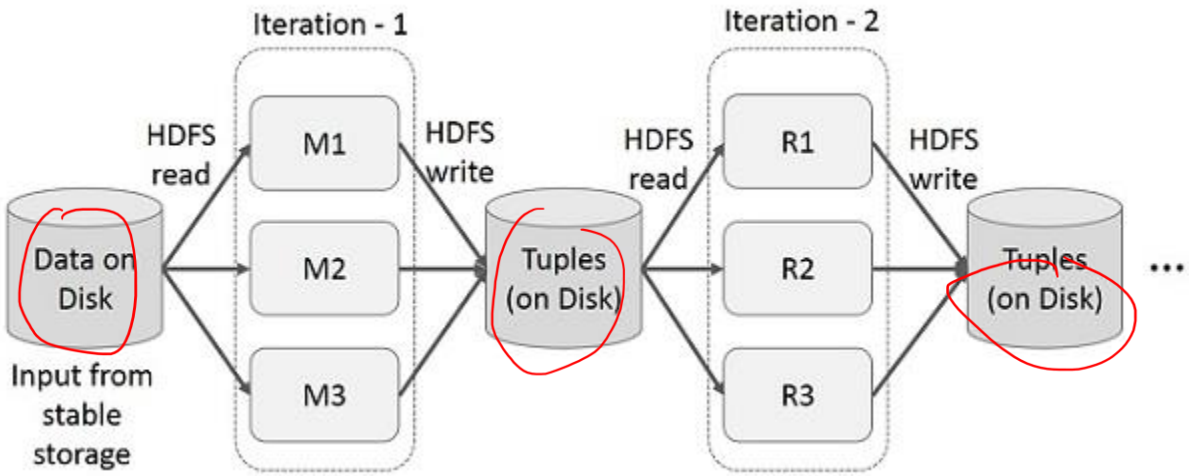

Interactive

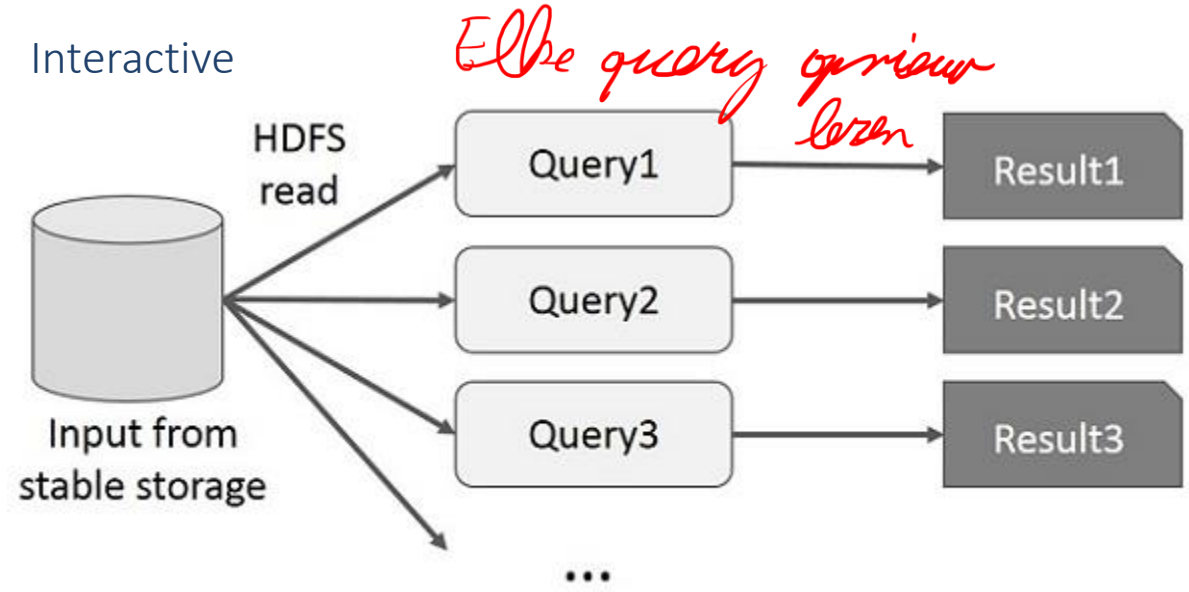

RDD is sneller

- In-memory sharing is 10 tot 100 keer sneller

Iterative

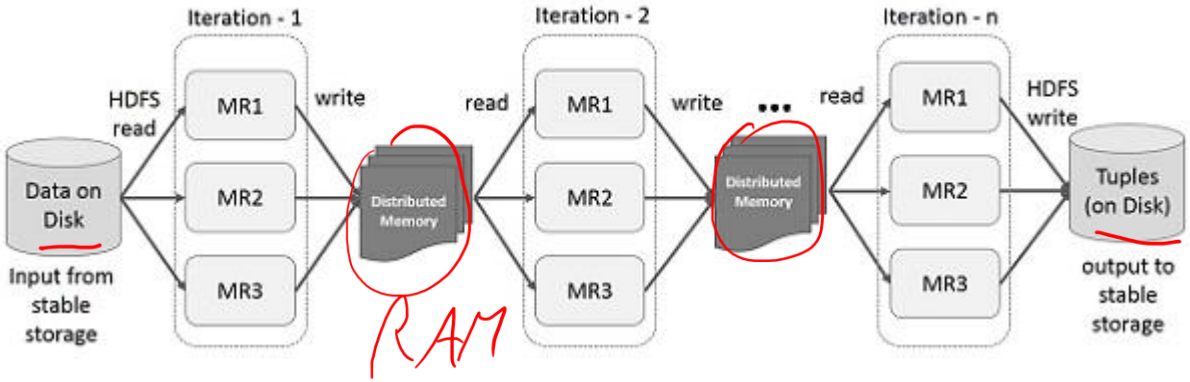

Interactive

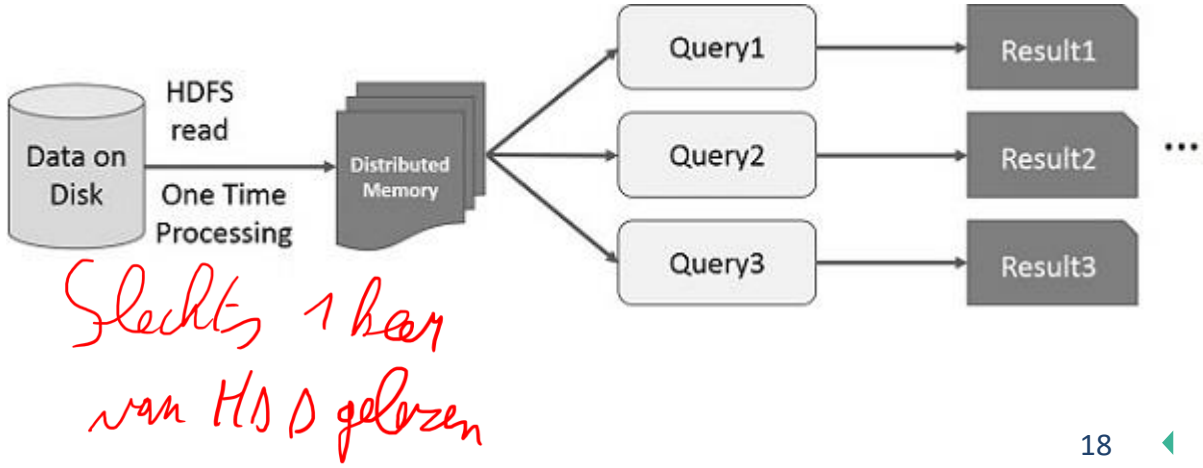

Installatie

- De python-installatie kan eenvoudig gebeuren via

```
(base) bigdata@bigdata-VirtualBox:~$ pip install pyspark
```

- Hierna kan het gebruikt worden in een notebook

```
In [2]: !pyspark --version
21/11/08 14:56:32 WARN Utils: Your hostname, bigdata-VirtualBox resolves to a loopback address: 127.0.1.1; using 10.
0.2.15 instead (on interface enp0s3)
21/11/08 14:56:32 WARN Utils: Set SPARK_LOCAL_IP if you need to bind to another address
WARNING: An illegal reflective access operation has occurred
WARNING: Illegal reflective access by org.apache.spark.unsafe.Platform (file:/home/bigdata/anaconda3/lib/python3.8/s
ite-packages/pyspark/jars/spark-unsafe_2.12-3.2.0.jar) to constructor java.nio.DirectByteBuffer(long,int)
WARNING: Please consider reporting this to the maintainers of org.apache.spark.unsafe.Platform
WARNING: Use --illegal-access=warn to enable warnings of further illegal reflective access operations
WARNING: All illegal access operations will be denied in a future release
Welcome to
      ____              __
     / __/__  ___ _____/ /__
    _\ \/ _ \/ _ `/ __/  '_/
   /___/ .__/\_,_/_/ /_/\_\   version 3.2.0
      /_/

Using Scala version 2.12.15, OpenJDK 64-Bit Server VM, 11.0.11
Branch HEAD
Compiled by user ubuntu on 2021-10-06T12:46:30Z
Revision 5d45a415f3a29898d92380380cfd82bfc7f579ea
Url https://github.com/apache/spark
Type --help for more information.
```

Features

- In memory processing
- Distributed processing via parallellisatie
- Werkt met verschillende clusterbeheerders (Spark, Yarn, …)
- Fout-tolerant
- Immutable/onverrandelijk -> nieuwe objecten ipv updates
- Lazy evaluation -> reken uit wanneer het nodig is
- Cache & persistentie
- Optimalisatie via dataframes
- Ondersteund een vorm van SQL

Sparksession

- Entry point voor de pyspark applicatie
  - ↳ waar moet ze uitgevoerd worden
- Kan aangemaakt worden via
  - Builder ()
  - newSession()
- Maakt intern een sparkcontext aan
- Maximum 1 context per JVM maar meerdere sessions mogelijk

Singleton

RDD

- Op basis van de huidige sessie kan een RDD aangemaakt worden
  - Basisobject in Spark
  - Kan verdeeld worden in logische delen en uitgevoerd worden op verschillende nodes

- Aangemaakt door
  - Nieuwe objecten -> parallelize()
  - Inlezen van files -> textFile / .read….
  - Opgevraagd uit (NO)SQL Databases

RDD - operaties

- Steeds in parallel

- Transformaties
  - Lazy operations (berekenen nog niets)
  - Geen updates maar een nieuw RDD gereturned
  - flatMap(), map(), reduceByKey(), filter(), sortByKey(), …
- Actions
  - Starten een berekening → enkel de nodige transformaties worden uitgevoerd
  - Count(), collect(), first(), max(), reduce(), …

DataFrames

- Gelijkaardig aan pandas dataframe
- Werken volledig in parallel

↳ distributed

```
In [60]: data = [('Harry', 'Potter','1980-07-31','M',100000000),
           ('Ronald','Wemel','1980-04-01','M',10),
           ('Hermelijn','Griffel','1979-09-19','F',4000)
         ]

         columns = ["firstname","lastname","dob","gender","budget"]
         df = spark.createDataFrame(data=data, schema = columns)
         df.show()
```

```
+---------+--------+----------+------+---------+
|firstname|lastname|       dob|gender|   budget|
+---------+--------+----------+------+---------+
|    Harry|  Potter|1980-07-31|     M|100000000|
|   Ronald|   Wemel|1980-04-01|     M|       10|
|Hermelijn| Griffel|1979-09-19|     F|     4000|
+---------+--------+----------+------+---------+
```

≈ pandas dataframe

→ Node 1
→ Node 2

Shared variables

- Normaal heeft elke node zijn eigen variabelen
- Shared variabelen met read-write access is zeer inefficient
- Twee types shared variabelen aanwezig
  - Broadcast variables
  - Accumulators

write once – read often

elke node schrijft → eind resultaat gelezen

Broadcast variables

- Read-only variable cached on each machine
- Eenmalig verstuurd ipv elke nieuwe job
- Aangemaakt via SparkContext.broadcast()
- Delete
  - Temporary: unpersist()
  - Permanent: destroy()

- Toepassingen
  - Grote input dataset op elke node krijgen

Accumulators

- Write-only shared variabelen waar enkel kan aan toegevoegd worden
  - Schrijven via .add()
- Enkel de driver kan het lezen via .value
- Applicaties
  - Counters
  - Sums
  - …
- Aangemaakt via SparkContext.accumulator()

Accumulators

- Standaard support voor numerieke accumulators, andere zelf te implementeren (overerven van AccumulatorParam)

- Let op dat Spark Lazy Evaluation doet
  - Schrijven naar de accumulator gebeurt enkel bij acties
  - Transformations kunnen dit ook doen maar worden slechts bij een actie uitgevoerd.

PySpark SQL

- Veel gebruikte module om sql-queries uit te voeren op dataframes.

```
In [65]: df.createOrReplaceTempView("test")
         df_male = spark.sql("select * from test where gender='M'")
         df_male.show()

         df_num_gender = spark.sql('select gender, count(*) from test group by gen
         df_num_gender.show()
```

```
+---------+--------+----------+------+---------+
|firstname|lastname|       dob|gender|   budget|
+---------+--------+----------+------+---------+
|    Harry|  Potter|1980-07-31|     M|100000000|
|   Ronald|   Wemel|1980-04-01|     M|       10|
+---------+--------+----------+------+---------+

+------+--------+
|gender|count(1)|
+------+--------+
|     F|       1|
|     M|       2|
+------+--------+
```

→ Geen intellisense bijdens coderen

→ Fout pas bij uitvoeren

→ Werken met queries breekt met code-stijl

Beantwoord de volgende vragen

- Waarom is Spark sneller dan MapReduce? Wat zijn de voor- en nadelen?
- Wat is lazy evaluation?
- Waarom kan pandas niet gebruikt worden als vervanger van Spark?